

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение высшего образования
«ТОМСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ СИСТЕМ УПРАВЛЕНИЯ
И РАДИОЭЛЕКТРОНИКИ» (ТУСУР)

Кафедра комплексной информационной безопасности
электронно-вычислительных систем (КИБЭВС)

Определение авторства исходного кода

ОТЧЕТ
по преддипломной практике

Студент гр. 722
_____ М.В. Мейта
«___» _____ 2017 г.

СОГЛАСОВАНО
Руководитель практики
от предприятия
к.т.н, доцент кафедры КИБЭВС
_____ Е.М. Давыдова
«___» _____ 2017 г.
Оценка отчета _____

Руководитель практики
к.т.н., доцент кафедры БИС
_____ А.С. Романов
«___» _____ 2017 г.

РЕФЕРАТ

Отчет содержит 28 страниц, 1 рисунок, 4 таблиц, 22 источников, 3 приложение.

СТИЛОМЕТРИЯ, ИСХОДНЫЙ КОД, ДЕАНОНИМИЗАЦИЯ АВТОРА, C++, КЛАССИФИКАЦИЯ, PYTHON, SKLEARN, RANDOM FOREST CLASSIFIER, LATEX.

Цель работы — разработка алгоритма для определения авторства программного обеспечения, основанного на стилометрическом анализе исходного кода программ на языках высокого уровня.

В рамках научно-исследовательской работы на текущий семестр были поставлены следующие задачи:

- обзор существующих исследований, разработок, методов стилометрического анализа текста, в том числе исходного кода программ;
- разработка алгоритм анализа исходного кода программ с применением стилометрии для определения авторства программного обеспечения;
- создание программной реализации разработанного алгоритма;
- исследование эффективности разработанного алгоритма анализа исходных кодов.

Объект исследования: деанонимизация автора программного обеспечения.

Предмет исследования: стилометрия исходного кода программ на языках высокого уровня.

В результате работы было выполнено следующее:

- произведен аналитический обзор существующих методов анализа исходного кода программ с целью деанонимизации автора;
- выбран набор признаков для классификации авторов программного кода на языке C++;
- в качестве алгоритма классификации выбран Random Forest Classifier;
- разработан алгоритм определения авторства исходного кода программ на языке C++;
- произведена программная реализация разработанного алгоритма на языке программирования высокого уровня Python;
- подготовлен тестовый набор данных;
- выбраны критерии оценки эффективности разработанного алгоритма;
- произведены вычислительные эксперименты на данном наборе данных;
- сделаны некоторые выводы на основе полученных результатов.

Отчет по преддипломной практике выполнен согласно ОС ТУСУР 01-2013 [1] при помощи системы компьютерной вёрстки L^AT_EX.

Содержание

Введение	5
1 Кафедра КИБЭВС	6
2 Обзор информационных источников	7
3 Выбор набора признаков, характеризующих автора программы	9
3.1 Лексические признаки	9
3.2 Ключевые слова C++	10
4 Классификация	11
4.1 Random Forest	12
4.2 AdaBoost	13
4.3 ExtraTrees	14
5 Инструменты разработки	15
6 Описание тестового набора данных	16
7 Критерии оценки эффективности классификации	18
8 Результаты классификации	19
Заключение	20
Список использованных источников	21
Приложение А Компакт-диск	23
Приложение Б Сравнительный обзор информационных источников	24
Приложение В Компакт-диск	26

Введение

С распространением применения компьютерных систем и сетей возросло и количество преступлений в информационной сфере. Существует множество разновидностей кибератак — различные компьютерные вирусы, трояны, несанкционированное копирование данных с кредитных карт, DDoS-атаки и многое другое. Возможность деанонимизации авторов вредоносного программного обеспечения может внести существенный вклад в развитие компьютерной криминалистики.

Целью данной работы является исследование методов стилометрии — статистического анализа текста для выявления его стилистических особенностей, а также методов машинного обучения для решения задачи деанонимизации разработчика по исходному коду программного обеспечения.

Определение авторства исходного кода представляет собой актуальную задачу в сфере информационной безопасности, лицензирования в области разработки программного обеспечения, а также может оказать существенную помощь во время судебных разбирательств, при решении вопросов об интеллектуальной собственности и плагиате.

1 Кафедра КИБЭВС

Местом прохождения практики была выбрана кафедра ТУСУРа – КИБЭВС (Кафедра комплексной информационной безопасности электронно-вычислительных систем).

Кафедра организована в ТУСУР в 1971 году как кафедра «Конструирования и производства электронно-вычислительной аппаратуры» (КиПЭВА) вскоре переименованной в кафедру «Конструирования электронно-вычислительной аппаратуры» (КЭВА).

21 сентября 1999 г. в связи с открытием новой актуальной специальности 090105 – «Комплексное обеспечение информационной безопасности автоматизированных систем» кафедра КЭВА была переименована в кафедру «Комплексной информационной безопасности электронно-вычислительных систем» (КИБЭВС). Заведующим кафедрой КИБЭВС, а также ректором ТУСУРа на сегодняшний день является ректор ТУСУРа, Александр Александрович Шелупанов, лауреат премии Правительства Российской Федерации, действительный член Международной Академии наук высшей школы РФ, действительный член Международной Академии информации, Почетный работник высшего профессионального образования РФ, заместитель Председателя Сибирского регионального отделения учебно-методического объединения вузов России по образованию в области информационной безопасности, профессор, доктор технических наук.

Кадровый состав непрерывно укреплялся с момента её образования в 1971 году. В 2011 году, в год 40-летия кафедры, её коллектив состоял из 53 человек, в их числе 34 опытных высококвалифицированных специалиста и 19 аспирантов. Среди сотрудников кафедры члены Академий наук РФ; 4 профессора; 12 доцентов, кандидатов наук; старшие научные сотрудники, кандидаты наук и др.

С 2008 г. кафедра КИБЭВС входит в состав Института «Системной интеграции и безопасности».

На базе кафедры КИБЭВС ТУСУР в 2002 году организовано «Сибирское региональное отделение учебно-методического объединения Вузов России по образованию в области информационной безопасности. [2]

2 Обзор информационных источников

На первом этапе практики необходимо было провести подробный аналитический обзор информационных источников, рассмотреть существующие методы определения авторства исходного кода и различные подходы к решению такого рода задачи.

В работе [3] представлен набор инструментов и техник, используемых для решения задач анализа авторства исходного кода, а также обзор некоторых наработок в данной предметной области. Кроме того, авторы приводят собственную классификацию проблем и подходов к их решению в рамках задачи деанонимизации авторов программного обеспечения.

Frantzeskou [3] выделяет следующие проблемы (задачи) анализа авторства исходного кода:

- идентификация автора — направлена на определение, принадлежит ли определенный фрагмент кода конкретному автору;
- характеристика автора — базируется на анализе стиля программирования;
- определение плагиата — нахождение схожестей среди множества фрагментов файлов исходного кода;
- определение намерений автора — был ли код изначально вредоносным или стал таковым в следствие программной ошибки;
- дискриминация авторов — определение, был ли код написан одним автором или несколькими.

Подходы к решению вышеперечисленных проблем (задач):

- анализ «вручную» — данный подход включает в себя исследование и анализ фрагмента исходного кода экспертом;
- вычисление схожести — базируется на измерении и сравнении различных метрик или токенов для набора файлов исходного кода;
- статистический анализ — в таком подходе используются статистические техники, такие как дискриминантный анализ и стилометрия, позволяющие определить различия между авторами;
- машинное обучение — используются методы рассуждения на основе прецедентов и нейронные сети для классификации автора на базе некоторого набора метрик.

В работе [4] предложен способ определения авторства программного обеспечения. в основе которого лежит статистический подсчет метрик, отражающих «почерк создателя» программного обеспечения. На основе метрик составлен «профиль почерка» программистов и вычисляется отклонение от данного профиля для каждого автора. Преимуществом данного метода является его независимость от языков программирования. Метод получил название SCAP (Source Code Author Profiles).

В [5] исходный код транслировался в абстрактные синтаксические деревья, после чего разби-

вался на функции. Дерево каждой функции принималось за отдельный документ с известным автором. Выборка, состоящая из такого рода деревьев подавалась на вход SVM-классификатору, оперирующему данными типа «дерево». Классификатор обучался на файлах исходного кода двух авторов, в результате чего удалось достичь точности около 67-88%.

В статье [6] рассматривался способ атрибуции исходного кода с использованием метода N-грамм. Вопрос определения авторства программ в данной работе рассматривался с точки зрения определения плагиата. В качестве выборки использовался набор из 1640 файлов исходного кода, написанных 100 авторами. Позднее удалось улучшить точность классификации данной модели до 77% за счет применения рейтинговых схем. [7]

Характерная особенность описанных выше работ состоит в том, что тестирование производилось на очень ограниченном наборе данных, в основном — студенческих работ или программных проектов, реализующих одну и ту же заранее поставленную в условиях эксперимента задачу.

В [8] применялся алгоритм классификации Random Forest [9] и построение абстрактных синтаксических деревьев. Обучение и тестирование производилось для количества авторов от 250 до 1600. При этом удалось добиться высокой точности — 94-98%. Кроме того, авторы статьи выяснили в ходе работы, что сложнее определить авторов более простых примеров, нежели сложных программ, а также значительно выделяются авторы с большим опытом программирования на C/C++. В своей дальнейшей работе [10] авторы предложили применение данного подхода для анализа неполных, некомпилируемых образцов кода.

На основании проведенного исследования было решено опробовать подход, основанный на вычислении статистических метрик, характеризующих авторский стиль написания программ, и методов машинного обучения.

Сравнительная таблица с подробным описанием данных информационных источников и используемых в них методов приведена **в приложении Б.**

3 Выбор набора признаков, характеризующих автора программы

Идентификация авторов исходного кода производилась на основании различных признаков, которые каким-либо образом могут идентифицировать так называемый стиль написания программ, присущий конкретному автору. Помимо деанонимизации автора, стиль написания кода может дать представление об уровне его квалификации, образовании, личных и профессиональных предпочтениях, а также некоторых других особенностях, которые могут представлять интерес в различного рода исследованиях.

Перечисленные в данном разделе признаки являются характерными для языков C и C++, однако могут быть использованы для исследования C-подобных языков, например, D, Java, Objective C, C#, PHP, perl и другие.

3.1 Лексические признаки

Главная особенность данной группы признаков состоит в том, что они могут быть вычислены при непосредственном анализе исходного кода программы в виде текстового файла. При этом код программы может быть некомпилируемым, неполным, содержащим синтаксические или программные ошибки.

Лексические признаки, как правило, улучшают читаемость кода и включают в себя:

- Стиль комментирования — данная подгруппа определяет преобладающий в тексте вид комментариев (однотрочные или многотрочные), а также общее их количество.
- Стиль расстановки фигурных скобок — к наиболее известным относят «K&R», «Whitesmith», «One True Bracing Style», стиль Алмена и другие. [11]
- Стиль разметки — расстановка пробелов, табуляций, число переносов строки к общей длине файла.

Дополнительно вычисляются:

- Число макросов — использует ли программист директивы препроцессора.[12]
- Средняя длина строки — позволяет также оценить читаемость кода (слишком длинные программные файлы плохо воспринимаются человеком).

В приложении В приведено описание использованных при классификации авторов признаков, а также формулы для их вычисления.

3.2 Ключевые слова C++

Ключевые слова C++ представляют собой список зарезервированных последовательностей символов, используемых языком, недоступных для переопределения.

Для ключевых слов языка C++ вычислялась статистическая мера TF (term frequency), отображающая число вхождения некоторого ключевого слова к общему количеству слов в документе. Подсчет частот ключевых слов может дать представление о предпочтениях автора в определенного рода конструкциях, например, циклов «for» относительно «while» или «do while», а также об уровне его профессиональной квалификации (определенные конструкции языка C/C++ используются крайне редко, сложны для понимания и предназначены для решения узкоспециализированных задач).

Словарь из 84 ключевых слов C++ (стандарт 11) был взят на сайте с официальной документацией [13] и представлен в таблице 3.1.

Таблица 3.1 – Ключевые слова языка C++ (стандарт 11)

Ключевые слова языка C++					
alignas	char32_t	enum	namespace	return	try
alignof	class	explicit	new	short	typedef
and	compl	export	noexcept	signed	typeid
and_eq	const	extern	not	sizeof	typename
asm	constexpr	false	not_eq	static	union
auto	const_cast	float	nullptr	static_assert	unsigned
bitand	continue	for	operator	static_cast	using
bitor	decltype	friend	or	struct	virtual
bool	default	goto	or_eq	switch	void
break	delete	if	private	template	volatile
case	do	inline	protected	this	wchar_t
catch	double	int	public	thread_local	while
char	dynamic_cast	long	register	throw	xor
char16_t	else	mutable	reinterpret_cast	true	xor_eq

4 Классификация

4.1 Random Forest

В качестве алгоритма классификации в данной работе был использован Random Forest Classifier, который строится на двух базовых принципах:

- bagging — мета-алгоритм в машинном обучении, при котором на основе большого числа «слабых» классификаторов (в данном случае деревьев решений) строится один «сильный» классификатор (рис. 4.1);

- метод случайных подпространств.

Преимущества данного алгоритма классификации:

- способность эффективно обрабатывать данные с большим числом признаков и классов;
- нечувствительность к масштабированию (к любым монотонным преобразованиям) значений признаков;

- существует методы оценивания значимости отдельных признаков в модели;

- внутренняя оценка способности модели к обобщению (тест out-of-bag);

- высокая параллелизуемость и масштабируемость.

Недостатки алгоритма Random Forest Classifier:

- алгоритм склонен к переобучению на некоторых задачах, особенно на зашумленных, однако для избежания переобучения используется энтропия Шеннона или коэффициент прироста информации (англ. Gain);

- большой размер получаемых моделей приводит к существенным затратам памяти на хранение деревьев, однако данный недостаток решается повышением вычислительных мощностей и распараллеливанием вычислений. [9]




Рисунок 4.1 – Random Forest Classifier

4.2 AdaBoost

4.3 ExtraTrees

5 Инструменты разработки

В качестве инструментов разработки были выбраны:

- 1) интерпретируемый высокоуровневый язык программирования Python версии 3.5.2; [14]
- 2) CastXML — синтаксический анализатор программ на языке C/C++ для построения абстрактных синтаксических деревьев в формате XML; [15]
- 3) pygccxml — библиотека на языке программирования Python для чтения XML-вывода CastXML (или ранней версии — GCCXML); [16]
- 4) scikit-learn — свободно распространяемая Python-библиотека для машинного обучения; [17]
- 5) matplotlib — библиотека на языке программирования Python для визуализации данных; [18]
- 6) интегрированная среда разработки PyCharm;
- 7) операционная система Linux Ubuntu 16.10.

6 Описание тестового набора данных

Burrows в работе [7] выделяет следующие ключевые параметры тестовых данных, которые могут влиять на точность классификации:

- Число авторов — с увеличением числа авторов сложность классификации увеличивается, точность — снижается.
- Число экземпляров выборки для каждого автора — желательно соблюдать одинаковым для всех авторов во избежание отклонения в сторону наиболее точно описанных авторов, а также иметь больше экземпляров для увеличения размера тестовой выборки.
- Средняя длина образца кода (количество непустых строк кода) — чем длиннее, тем выше точность классификации. Изменение длины экземпляров выборки может влиять на отклонение в сторону наиболее точно описанных авторов, однако не представляется возможным соблюдать длину экземпляра выборки постоянной.
- «Стилистическая зрелость» (stylistic maturity) авторов — уровень квалификации, личные и профессиональные предпочтения в стиле написания программ.
- Временные метки образцов кода (подразумевается, что со временем программы устаревают, технологии и методы программирования меняются и, как следствие, изменяется стиль программирования).
- Репрезентативность выборки — демографические, социальные и другие факторы.
- Типы авторов — студент, фрилансер, профессиональный разработчик. В идеале система должна включать в себя разные типы.
- Языки программирования — если тестировать несколько языков одновременно, результат будет зависеть от характерных признаков языка.
- Авторство в одном лице — большинство проектов выполняются в сотрудничестве с другими разработчиками.
- Корректное авторство — без плагиата, копирования и т.п.

Burrows упоминает также о том, что характерный стиль программирования нестабилен в начале карьеры программиста, что может существенно отличать начинающего специалиста и профессионала разработки.

Программное обеспечение «WhoseCppClassCode» тестировалось на трех наборах данных:

1) «Students» — выборка представляет собой работы студентов первого курса обучения по предмету «Основы программирования». Все программы реализуют решения однотипных задач в рамках учебной дисциплины, что исключает их разделение при классификации по функциональному назначению вместо стилистических особенностей и снижение точности классификации.

2) «Google Code Jam» — общедоступные данные ежегодной международной олимпиады по

программированию Google Code Jam 2016. [19] Так же, как и в первой выборке, авторы решали схожие задачи, используя различные подходы и алгоритмы.

3) «GitHub» — данные, собранные с сайта GitHub [20] — крупнейшего [21] веб-сервиса для хостинга IT-проектов и их совместной разработки.

Сбор данных с веб-хостинга GitHub производился по следующему принципу:

1) Выбирались крупные open-source репозитории (удаленные хранилища программного кода и данных), посвященные разработке проектов на C/C++.

2) Просматривался список контрибьюторов (пользователей, вносивших изменения в проект).

3) В качестве авторов выбирались те контрибьюторы, у которых имеются личные проекты, написанные на C/C++.

4) На основе списка пользователей автоматически, средствами программы «WhoseCppCode», производился сбор и сохранение файлов исходного кода для каждого автора.

В таблице 6.1 приводится описание некоторых характеристик каждого набора данных. В данном случае под смешанным типом авторов подразумевается, что разработчики могли быть совершенно разного уровня квалификации и рода деятельности (студенты, фрилансеры, начинающие и профессиональные разработчики, программисты-любители и т.д.).

Таблица 6.1 – Тестовые данные

Набор данных	«Students»	«Google Code Jam»	«GitHub»
Число авторов	3	30	30
исло файлов исходного кода на одного автора	14	9	78
Всего файлов исходного кода	42	278	2334
Минимальное число строк кода	33	36	26
Максимальное число строк кода	160	461	16348
Среднее число строк кода на один файл исходного кода	45	87	234
Тип авторов	Студенты	Смешанный	Смешанный

Каждая выборка представляет собой совокупность файлов исходного кода программ на языке C/C++ с расширениями *.cpp, *.c, *.h, *.hpp, *.cxx, *.cc, *.ii, *.ixx, *.ipp, *.inl, *.txx, *.tpp, *.tpl.

Тестовая и обучающая выборки генерировались случайным образом без повторений из начальной выборки, описанной выше. При этом четверть всех примеров использовалась для тестирования (классификации), а также использовалась процедура скользящего контроля — **10-фолдовая кросс-**

валидация. Подробное описание процедуры разбиения данных и тестирования **обучаемой модели** содержится в разделах

7 Критерии оценки эффективности классификации

Критерии оценки работы классификатора представлены в таблице 7.1, где:

- tp — истинно-положительное решение;
- tn — истинно-отрицательное решение;
- fp — ложно-положительное решение;
- fn — ложно-отрицательное решение;
- Accuracy (точность) — отношение количества документов, по которым классификатор принял правильное решение, к общему числу документов (примеров файлов исходного кода);
- Precision (правильность) — доля документов, действительно принадлежащих данному классу, относительно всех документов, которые система отнесла к этому классу;
- Recall (полнота) — доля найденных классификатором документов, принадлежащих классу, относительно всех документов этого класса в тестовой выборке;
- F1-score (F1-мера) — гармоническое среднее между правильностью и полнотой. [22]

Таблица 7.1 – Критерии оценки работы классификатора

Критерий	Формула	Луч. знач.	Худ. знач.
Accuracy (точность)	$(tp + tn) / \text{число примеров} * 100 \%$	100 %	0 %
Precision (правильность)	$tp / (tp + fp)$	1	0
Recall (полнота)	$tp / (tp + fn)$	1	0
F1-score (F1-мера)	$2 * (precision * recall) / (precision + recall)$	1	0

8 Результаты классификации

При тестировании классификатора использовались критерии оценки, описанные в разделе 7, а также время работы программы. Результаты работы классификатора представлены в таблице 8.1.

Таблица 8.1 – Результаты работы

Набор данных «Students»					
Классификатор	Accuracy, %	Precision	Recall	F1-score	Время работы, сек.
RandomForest	89,55	0,90	0,93	0,90	93,61
AdaBoost	70,45	0,70	0,74	0,70	53,22
ExtraTrees	91,85	0,92	0,95	0,92	53,70
Набор данных «Google Code Jam»					
Классификатор	Accuracy, %	Precision	Recall	F1-score	Время работы, сек.
RandomForest	86,66	0,86	0,88	0,87	110,65
AdaBoost	19,43	0,16	0,16	0,19	103,53
ExtraTrees	88,09	0,88	0,90	0,88	60,34
Набор данных «GitHub»					
Классификатор	Accuracy, %	Precision	Recall	F1-score	Время работы, сек.
RandomForest	69,92	0,69	0,71	0,70	223,77
AdaBoost	16,44	0,09	0,11	0,16	451,63
ExtraTrees	70,99	0,70	0,72	0,71	201,13

Заключение

По результатам, полученным в ходе научно-исследовательской работы, можно сделать следующие выводы:

1) Тестовые данные (см. раздел 6) имели определенные недостатки, которые в конечном итоге привели к снижению точности классификации:

- программы, на которых производилось обучение и тестирование классификатора, были написаны студентами в ходе изучения основ программирования, т.е. у авторов в выборке отсутствовал опыт программирования на C/C++;
- среднее количество строк кода на файл составило всего 45 строк;
- в основном примеры содержали множество конструкций ввода-вывода и простые расчеты (например, площадей различных геометрических фигур);
- задания выполнялись по примерам из методического обеспечения, что повлияло на предпочтение использования тех или иных конструкций языка.

2) Не все признаки, используемые в классификации, равнозначны. Так, например, частоты ключевых слов «int» или «float» (см. раздел 3.2) не так важны для определения стилистических особенностей написания программы, как, к примеру, определенные предпочтения автора при назначении идентификаторов.

3) Оптимальные параметры для задач классификации с помощью алгоритма Random Forest (см. раздел 4.1) были подобраны эмпирически (см. раздел ??) и соответствовали рекомендациям из различных источников.

В ходе работы был построен классификатор, позволяющий отнести исходный код к конкретному автору с точностью около 73%.

Среди задач на будущее можно выделить следующие:

- расширение набора признаков, а также расчет (с использованием экспертной оценки) веса для каждого из них (см. раздел 3) для повышения точности классификации;
- подбор тестовых данных более сложных программ для большего количества авторов; при этом желательно, чтобы авторы программ имели некоторый опыт программирования на языке C/C++;
- исследование набора признаков для программ на других языках высокого уровня;
- исследование алгоритмов обнаружения плагиата в исходных кодах программ.

Список использованных источников

- 1 Образовательный стандарт ВУЗа ОС ТУСУР 01-2013 [Электронный ресурс]. — Режим доступа: https://storage.tusur.ru/files/40668/rules_tech_01-2013.pdf (дата обращения: 15.12.2016).
- 2 Кафедра комплексной информационной безопасности электронно-вычислительных систем [Электронный ресурс]. — Режим доступа: [доступа: http://kibevs.tusur.ru/pages/kafedra/index](http://kibevs.tusur.ru/pages/kafedra/index) (дата обращения: 01.05.2017).
- 3 Source Code Authorship Analysis For Supporting The Cybercrime Investigation Process. Georgia Frantzeskou, Efstathios Stamatatos, Stefanos Gritzalis [Электронный ресурс]. — Режим доступа: <http://www.icsd.aegean.gr/lecturers/stamatatos/papers/ICETE2005.pdf> (дата обращения: 23.10.2016).
- 4 Identifying Authorship by Byte-Level N-Grams: The Source Code Author Profile (SCAP) Method. Georgia Frantzeskou, Efstathios Stamatatos, Stefanos Gritzalis [Электронный ресурс]. — Режим доступа: <https://www.semanticscholar.org/paper/Identifying-Authorship-by-Byte-Level-N-Grams-The-Frantzeskou-Stamatatos/3b2531ea2685b9fb9abf071d119974ac3405874d> (дата обращения: 15.02.2017).
- 5 Using Classification Techniques to Determine Source Code Authorship. Brian N. Pellin Computer Sciences Department University of Wisconsin [Электронный ресурс]. — Режим доступа: <https://pdfs.semanticscholar.org/f9aa/790191a50bed02a877e1696c7bb71ea9f33a.pdf> (дата обращения: 23.10.2016).
- 6 Source Code Authorship Attribution using n-grams. Steven Burrows, S.M.M. Tahaghoghi [Электронный ресурс]. — Режим доступа: <https://pdfs.semanticscholar.org/79a2/1998c2f0afe2c616c01d590d6d0f6e16e9eb.pdf> (дата обращения: 23.10.2016).
- 7 Source Code Authorship Attribution. Steven Burrows [Электронный ресурс]. — Режим доступа: <http://researchbank.rmit.edu.au/eserv/rmit:10828/Burrows.pdf> (дата обращения: 23.10.2016).
- 8 De-anonymizing Programmers via Code Stylometry. Aylin Caliskan-Islam, Drexel University; Richard Harang, U.S. Army Research Laboratory; Andrew Liu, University of Maryland; Arvind Narayanan, Princeton University; Clare Voss, U.S. Army Research Laboratory; Fabian Yamaguchi, University of Goettingen; Rachel Greenstadt, Drexel University [Электронный ресурс]. — Режим доступа: <https://www.usenix.org/system/files/conference/usenixsecurity15/sec15-paper-caliskan-islam.pdf> (дата обращения: 07.09.2016).

- 9 Random Forest. Applied Multivariate Statistics — Spring 2012 [Электронный ресурс]. — Режим доступа: <http://stat.ethz.ch/education/semesters/ss2012/ams/slides/v10.2.pdf> (дата обращения: 23.10.2016).
- 10 Git Blame Who?: Stylistic Authorship Attribution of Small, Incomplete Source Code Fragments. Edwin Dauber, Aylin Caliskan, Richard Harang, Rachel Greenstadt [Электронный ресурс]. — Режим доступа: <https://arxiv.org/abs/1701.05681> (дата обращения: 10.03.2017).
- 11 Хэзфилд Р. Искусство программирования на С. Фундаментальные алгоритмы, структуры данных и примеры приложений. Энциклопедия программиста / Р. Хэзфилд, Л. Кирби. — М: . ДиаСофт, 2001. — 736 с.
- 12 Макросы (C/C++) [Электронный ресурс]. — Режим доступа: <https://msdn.microsoft.com/ru-ru/library/503x3e3s.aspx> (дата обращения: 23.02.2017).
- 13 Ключевые слова C++ [Электронный ресурс]. — Режим доступа: <http://ru.cppreference.com/w/cpp/keyword> (дата обращения: 12.10.2016).
- 14 Python 3.5.2 [Электронный ресурс]. — Режим доступа: <https://www.python.org/> (дата обращения: 25.10.2016).
- 15 CastXML C-family Abstract Syntax Tree XML Output [Электронный ресурс]. — Режим доступа: <https://github.com/CastXML/CastXML> (дата обращения: 25.10.2016).
- 16 Pygccxml — pygccxml 1.8.3 documentation [Электронный ресурс]. — Режим доступа: <http://pygccxml.readthedocs.io/en/develop/> (дата обращения: 25.10.2016).
- 17 Scikit-learn — Machine Learning in Python [Электронный ресурс]. — Режим доступа: <http://scikit-learn.org/stable/> (дата обращения: 25.10.2016).
- 18 Matplotlib: Python Plotting [Электронный ресурс]. — Режим доступа: <http://matplotlib.org/> (дата обращения: 25.10.2016).
- 19 Code Jam Language Stats [Электронный ресурс]. — Режим доступа: <https://www.google.com/codejam/contest/66766/dashboard#s=p16> (дата обращения: 10.02.2017).
- 20 GitHub [Электронный ресурс]. — Режим доступа: <https://github.com/> (дата обращения: 10.05.2017).
- 21 GitHub Dominates the Forges [Электронный ресурс]. — Режим доступа: <https://github.com/blog/865-github-dominates-the-forges> (дата обращения: 10.05.2017).
- 22 Оценка классификатора (точность, полнота, F-мера) [Электронный ресурс]. — Режим доступа: <http://bazhenov.me/blog/2012/07/21/classification-performance-evaluation.html> (дата обращения: 17.12.2016).

Приложение А

(Обязательное)

Компакт-диск

Компакт-диск содержит:

- электронную версию пояснительной записки в форматах *.tex и *.pdf;
- итоговую презентацию результатов работы в форматах *.pptx и *.pdf;
- актуальную версию программы, реализованную на языке программирования Python, для определения авторства исходного кода программ на языке C/C++;
- тестовые данные для работы с программой.

Приложение Б

(Обязательное)

Сравнительный обзор информационных источников

Приложение Б
Обзор источников

Название работы	Авторы, год публикации	Методы, использованные в работе	Описание данных	Достигнутая точность классификации	Язык программирования
Using classification techniques to determine source code authorship	B. Pellin, 2008	АСТ, SVM	4 схожие программы, 2 автора	67 — 88 %	Java
Source code authorship attribution using n-grams	S. Burrows, S. Tahaghoghi, 2007	N-граммы	Выборка из 1640 файлов исходного кода и 100 авторов	67 %	C
Identifying Authorship by Byte-Level N-Grams: The Source Code Author Profile (SCAP) Method	G. Frantzeskou, E. Stamatatos, S. Gritzalis, 2007	Составление профиля программиста на основе статистических метрик, подсчет отклонения от профиля	Не указано	88 % для C++, 100 % для Java	Java, C++
Application of information retrieval techniques for source code authorship attribution	S. Burrows, A. Uitdenbogerd, T. Urpin, 2009	N-граммы, рейтинговые схемы	100 авторов, классифицировались по 10, 1579 программных файлов	77 %	C
De-anonymizing Programmers via Code Stylometry	A. Caliskan-Islam, R. Harang, A. Liu, F. Yamaguchi, 2015	Статистический подсчет признаков, нечеткие АСТ	250 авторов, 1600 файлов	94 — 98 %	C/C++, Python
Git Blame Who?: Stylistic Authorship Attribution of Small, Incomplete Source Code Fragments	A. Caliskan-Islam, E. Dauber, R. Harang, R. Greenstadt, 2017	Калибровочные кривые, нечеткие АСТ, классификатор Random Forest	Некомпилируемые неполные образцы кода с ресурса GitHub	70 — 100 %	C/C++

Приложение В
(Обязательное)
Компакт-диск

Приложение В
Описание лексических признаков

Группа признаков	Признак	Обозначение	Определение
Стиль комментирования	Число однострочных комментариев	ln_inline_comments	Натуральный логарифм отношения числа однострочных комментариев к длине файла в символах
	Число многострочных комментариев	ln_multiline_comments	Натуральный логарифм отношения числа многострочных комментариев к длине файла в символах
	Число комментариев	ln_comments	Натуральный логарифм отношения числа комментариев к длине файла в символах
Стиль разметки	Число пробелов	ln_spaces	Натуральный логарифм отношения числа пробелов к длине файла в символах
	Число символов табуляции	ln_tabs	Натуральный логарифм отношения числа символов табуляции к длине файла в символах
	Число переводов строки	ln_newlines	Натуральный логарифм отношения числа переводов строки к длине файла в символах
	Коэффициент пробельных символов	whitespace_ratio	Натуральный логарифм отношения суммы всех пробельных символов (пробелов, символов табуляции, переводов строки) к длине файла в символах
Стиль расстановки фигурных скобок	Число раскрывающихся скобок, одиночных в строке	ln_open_brace_alone	Натуральный логарифм отношения числа раскрывающихся скобок, одиночных в строке, к длине файла в символах
	Число раскрывающихся скобок, первых в строке	ln_open_brace_first	Натуральный логарифм отношения числа раскрывающихся скобок, после которых следует код, к длине файла в символах
	Число раскрывающихся скобок, последних в строке	ln_open_brace_last	Натуральный логарифм отношения числа раскрывающихся скобок, которым предшествует код, к длине файла в символах

Продолжение таблицы

Группа признаков	Признак	Обозначение	Определение
Стиль расстановки фигурных скобок	Число закрывающихся скобок, одиночных в строке	ln_closing_brace_alone	Натуральный логарифм отношения числа закрывающихся скобок, одиночных в строке, к длине файла в символах
	Число закрывающихся скобок, первых в строке	ln_closing_brace_first	Натуральный логарифм отношения числа закрывающихся скобок, после которых следует код, к длине файла в символах
	Число закрывающихся скобок, последних в строке	ln_closing_brace_last	Натуральный логарифм отношения числа закрывающихся скобок, которым предшествует код, к длине файла в символах
Дополнительные признаки	Число макросов	ln_macros	Натуральный логарифм отношения числа макросов к длине файла в символах
	Число строк кода	lines_of_code	Число строк кода, не включающее пустые строки